PROYECTO FINAL · INTELIGENCIA ARTIFICIAL

Detección de derrame pleural en radiografías de tórax

Informe del proceso completo: dataset, limpieza, balanceo al 40%, entrenamiento, tiempos y resultados de cada modelo

Autores: Tiziano Bertorello, Marcos Agustín García Mombello y Martin Mousist
Ingeniería en Informática · Facultad de Ingeniería, CRU Córdoba - IUA, Universidad de la Defensa Nacional
Docente: Ing. Hernando Alexis González · Noviembre de 2026
Repositorio: github.com/Marcouzis11/iaproyecto, rama `main`

Resumen

Entrenamos una red neuronal que mira una radiografía de tórax de frente (vista PA) y dice si tiene **derrame pleural** (*Effusion*): líquido entre el pulmón y la pared del tórax. Usamos el dataset público **NIH ChestX-ray14**, con 40% de imágenes positivas en cada conjunto, como pidió el profesor. Probamos cuatro modelos y medimos el éxito con el **F1-Score**, la métrica que propone la consigna.

Modelo B, submuestra del test oficial (4.390 imágenes)	Modelo C, test nuevo (1.313 imágenes)	Referencia sin IA: decir siempre "tiene derrame"	Ejemplo de objetivo de la consigna
0,744	**0,784**	**0,571**	**0,80**
F1 · IC 95%: 0,726 a 0,761	F1 · IC 95%: 0,736 a 0,823	F1 con 40% de positivas	No alcanzado en test

- **El modelo aprende algo real.** En pacientes que nunca vio separa las dos clases con AUC entre 0,87 y 0,90, y su F1 supera con holgura a la referencia trivial.
- **No llegamos a 0,80 en ningún test.** En validación sí se llegó, pero esa cifra es optimista, porque con validación se eligieron la época y el umbral.
- **Entre las dos formas de balancear no se detectó una diferencia significativa en F1.** Repetir positivas (B) en lugar de sacar negativas (A) detecta más derrames, a cambio de más falsas alarmas.
- **El modelo C bajó los falsos positivos de forma significativa**, pero la mejora en F1 no lo es.
- **Tiempo total de entrenamiento:** 3 h 8 min para los cuatro modelos, en una MacBook Air con chip M4.

1 El problema y cómo se mide

- **Clasificación binaria.** La clase **1** es una imagen con la etiqueta *Effusion*, sola o junto a otros hallazgos. La clase **0** es cualquier radiografía sin esa etiqueta: puede ser normal o tener otra enfermedad.
- **Solo vista PA** (posteroanterior, el paciente de pie). La vista AP se toma en cama, a pacientes más graves, y cambia el aspecto de la imagen. Mezclarlas le daría al modelo un atajo: reconocer el tipo de toma en lugar del derrame.
- **40% de positivas en train, validación y test**, como pidió el profesor.
- **Separación por paciente.** Un mismo paciente nunca aparece en dos conjuntos. Si apareciera, el modelo podría reconocer a la persona en lugar del hallazgo.

F1 = 2 · precisión · recall / (precisión + recall)

Recall: de los derrames reales, cuántos detecta. **Precisión:** de las alarmas que da, cuántas son derrames. El F1 los combina y no cuenta los verdaderos negativos, así que no se infla como la exactitud cuando hay más negativas. La referencia sin IA es responder siempre "tiene derrame". Con 40% de positivas, eso da precisión 0,40, recall 1 y F1 **0,571**.

2 El dataset

NIH ChestX-ray14 (National Institutes of Health, EE. UU.) tiene **112.120 radiografías de tórax** de 30.805 pacientes, en PNG de 1024×1024. Cada imagen trae una o más de 14 etiquetas de hallazgos, o *No Finding*. El CSV de metadatos (`Data_Entry_2017_v2020.csv`) agrega el paciente, la edad, el sexo, la vista (PA o AP) y el número de estudio de seguimiento (`Follow-up #`). NIH publica además dos listas oficiales, `train_val_list.txt` y `test_list.txt`, ya separadas por paciente.

Las etiquetas no las puso un radiólogo imagen por imagen. NIH las extrajo automáticamente de los informes médicos con procesamiento de lenguaje natural, así que tienen errores. Lo vimos en el análisis de errores: hay imágenes etiquetadas *No Finding* que muestran opacidades evidentes.

Primer intento: Pneumothorax

Empezamos con *Pneumothorax* (aire en la pleura), con solo 2 de las 12 carpetas descargadas: 14.999 imágenes, de las que 9.882 eran PA. Train quedaba con **3,6% de positivas (267 imágenes)**, demasiado pocas para entrenar una red y lejos del 40% pedido. Por eso descargamos el dataset completo y cambiamos a **Effusion**, que en vista PA tiene **6.589 imágenes positivas**.

Durante la descarga apareció un problema: la carpeta `images 10` resultó ser una copia de `images 12`, así que descargamos de nuevo `images_010`. La búsqueda de duplicados por hash, que se describe abajo, garantiza que una copia así no termine en dos conjuntos.

3 Limpieza de los datos

La preparación está en `rx_torax.prepare` y se corre con un archivo de configuración (`configs/nih.json`). Cada fila del CSV termina **aceptada o excluida con su motivo** en `exclusiones.csv`; al final se verifica que las dos sumen las 112.120 filas.

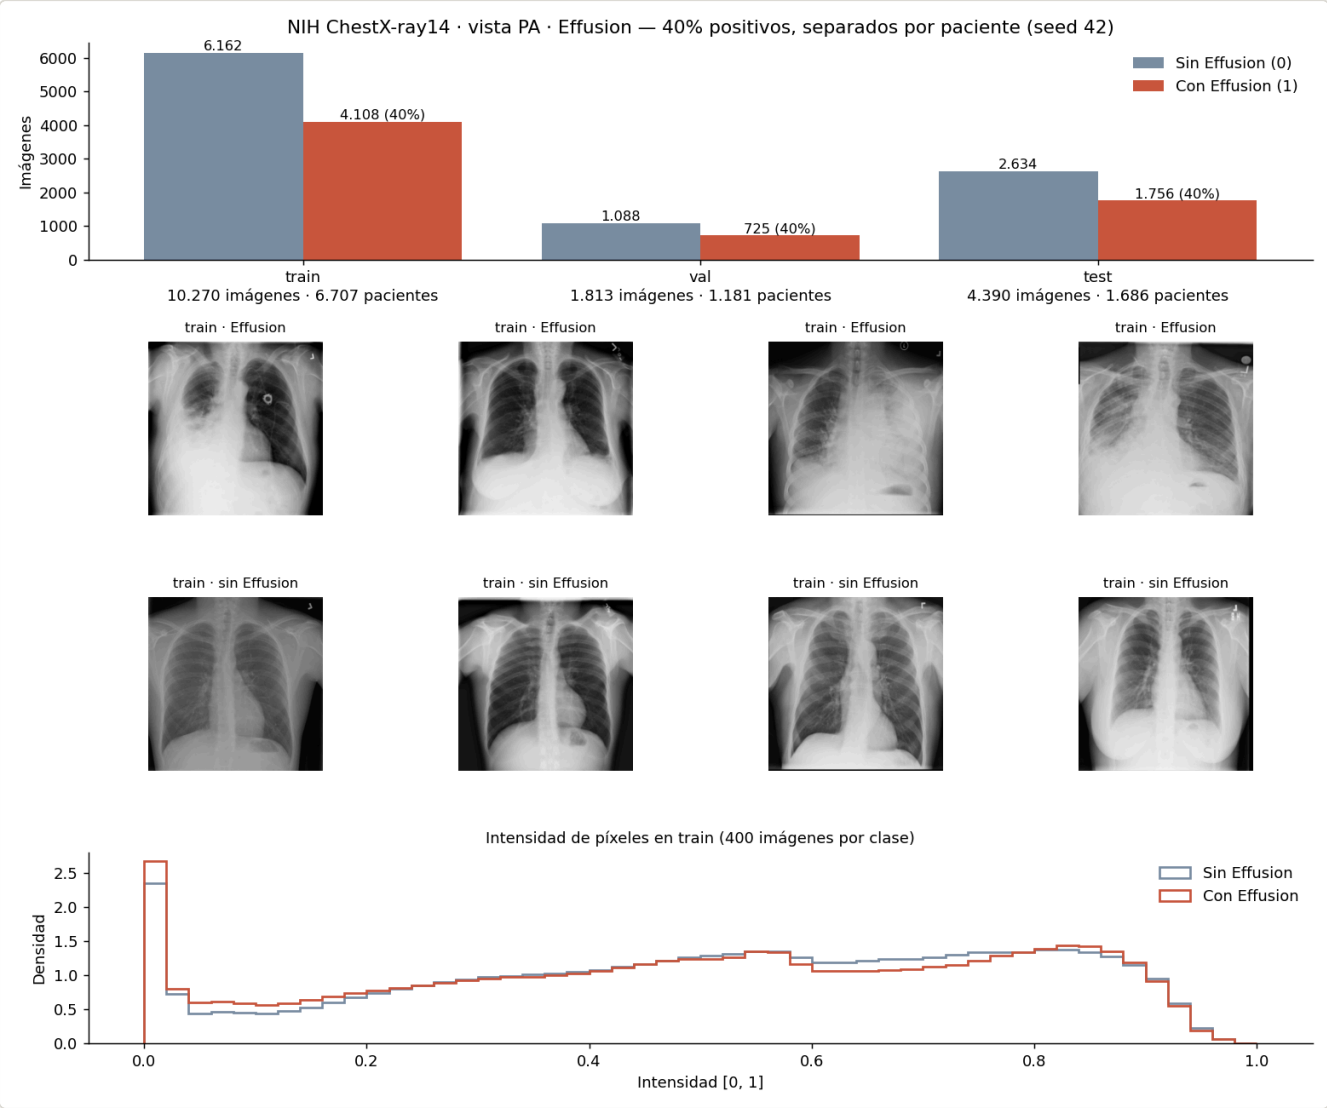
Paso	Filas	Qué se hizo
Filas del CSV de NIH	112.120	Todas las imágenes, con sus etiquetas y metadatos
Vista AP	−44.810	Excluidas: solo se usa la vista PA
Duplicados exactos del mismo paciente	−3	Se conserva una copia de cada imagen repetida
Duplicados entre pacientes distintos	−9	Se excluyen todas las copias: no se sabe de quién es la imagen
Radiografías PA aceptadas	**67.298**	**De ellas, 6.589 con Effusion (9,8%)**

1. **Validación de etiquetas y columnas.** Cada fila necesita paciente, vista y etiquetas válidas. Por ejemplo, *No Finding* no puede aparecer junto a otro hallazgo.
2. **Auditoría de archivos.** Se abre cada imagen, se registran su tamaño, modo y profundidad, y se excluyen las ausentes o ilegibles. No hubo ninguna.

3. **Duplicados.** Se calcula un hash de los píxeles de cada imagen. Si dos archivos son idénticos y del mismo paciente, se queda uno; si los pacientes, las etiquetas o los conjuntos no coinciden, se descartan todos.
4. **Calidad de imagen.** En una muestra de 4.000 radiografías PA, el 0,3% tenía marcos blancos y el 1,3% poco contraste. Todas eran legibles, así que no se filtró ninguna.
5. **Dispositivos médicos.** En una muestra de 96 imágenes revisadas a ojo, se ven cables, catéteres o puertos en ~30% de las positivas y ~13% de las negativas. NIH no los marca, así que quedaron incluidos. El modelo podría usarlos como atajo; es una limitación conocida.

Transformación de cada imagen

- **Escala de grises**, con intensidades llevadas a [0, 1].
- **224×224 sin deformar.** Se reduce manteniendo la proporción y se completa con bordes negros. 224 es el tamaño con el que se preentrenó la red.
- **Media y desvío calculados solo con train** (0,508 y 0,265 en la primera versión). Se guardan en `preprocessing.json` y se aplican sin recalcular a validación, test e imágenes nuevas, como se vio en clase: separar, calcular en train y aplicar a todos.



Conjuntos de la primera versión (modelos A y B), ejemplos de train con y sin derrame, ya transformados a 224×224, e histograma de intensidades por clase.

4 Separación en train, validación y test

- **Test:** el test oficial de NIH (`test_list.txt`), solo vista PA. Se usan todas sus positivas y negativas elegidas como en train, así que es una submuestra del test oficial.
- **Validación:** el 15% de los pacientes de `train_val_list.txt` . Con seed 42 se prueban 1.000 repartos por paciente y se queda el que mejor se acerca a las proporciones buscadas.
- **Train:** el resto de los pacientes de `train_val_list.txt` .
- **Verificaciones automáticas:** 0 pacientes compartidos entre conjuntos, 0 imágenes idénticas entre conjuntos y las dos clases presentes en cada uno.

5 Cómo llevamos las positivas al 40%

En los datos reales el derrame es poco frecuente: **9,8%** de las radiografías PA (6.589 de 67.298) y 15,8% en el test oficial. El profesor pidió **40%**. Comparamos dos formas de lograrlo en train:

> **Modelo A: sacar negativas**
>
> Se usan **todas** las positivas (4.108 en train) y se elige al azar la cantidad justa de negativas para llegar al 40%: 6.162. Total: 10.270 imágenes.

> **Modelo B: repetir positivas**
>
> Cada positiva aparece **3 veces por época** (sobremuestreo). Así se pueden usar más negativas distintas: 18.486. Por época ve 30.810 muestras, con 40% de positivas.

- **Mezcla de negativas.** 65% sin hallazgos y 35% con otros hallazgos, la misma mezcla que hay en PA, para que el modelo aprenda a distinguir el derrame de otras enfermedades y no solo de radiografías normales.
- **Hasta 3 negativas por paciente**, para que ningún paciente pese demasiado.
- **Validación y test también tienen 40%.** Ahí solo se eligen negativas al azar con seed fija; nunca se repiten imágenes ni se generan sintéticas. En clase se balancea solo train (slides 06, pp. 29, 31 y 35; notebook de desbalance, celdas 14 y 15); acá también se ajustan validación y test porque el profesor pidió el mismo porcentaje en train y test. La mezcla de negativas (65% sin hallazgos, como máximo 3 por paciente) también se aplicó en validación y test, y el 65% se tomó de todas las negativas PA, test incluido: con la mezcla natural del test oficial, la especificidad de B sería de 54% a 59% en lugar de 62%.

Conjuntos de la primera versión. Validación y test son idénticos byte a byte para A y B.

Conjunto	Imágenes	Pacientes	Con Effusion	Sin hallazgos	Otros hallazgos
Train del modelo A	10.270	6.707	4.108 (40%)	4.005	2.157
Train del modelo B	22.594	13.914	4.108 (×3 por época)	18.486 negativas	
Validación	1.813	1.181	725 (40%)	707	381
Test oficial	4.390	1.686	1.756 (40%)	1.712	922

> **Consecuencia:** con 40% de positivas, la precisión y el F1 salen más altos que con la proporción real. Con el recall y la especificidad que tuvo el modelo B en test, el F1 sería 0,47 con 15,8% de positivas y 0,34 con 9,8%. Recall, especificidad y AUC dependen mucho menos de la proporción.

6 Entrenamiento

Configuración común a los cuatro modelos

Red	DenseNet121 preentrenada en ImageNet (transfer learning). La última capa se reemplaza por una sola salida: la probabilidad de derrame.
Entrada	Imagen gris de 224×224, normalizada con la media y el desvío de train y copiada a 3 canales, como espera la red.
Pérdida y optimizador	Entropía cruzada binaria. AdamW con learning rate 0,0001 y weight decay 0,0001. Lotes de 32 imágenes.
Augmentation	Solo en train: rotación de ±7°, escala de ±5% y desplazamiento de ±5%, al azar en cada imagen. Sin espejar, porque el tórax no es simétrico (el corazón está a la izquierda).
Épocas	Hasta 15. Si el AUC de validación no mejora en dos épocas seguidas, el learning rate se multiplica por 0,3. Si no mejora en 4, se corta (*early stopping*) y se queda la mejor época.
Umbral	La red da una probabilidad; el umbral que la convierte en sí o no se elige en validación, maximizando el F1, y se guarda junto al modelo. Nunca se ajusta con test.
Reproducibilidad	Seed 42 en todo. Python 3.11, PyTorch 2.15, torchvision 0.29, NumPy 2.3.
Hardware	MacBook Air con chip M4, usando la GPU con MPS.

Tiempos de entrenamiento

Modelo	Imágenes de train	Muestras por época	Épocas corridas	Mejor época	Tiempo
A: sacar negativas	10.270	10.270	7	3	48 min
B: repetir positivas	22.594	30.810	5	1	79 min
Control (segunda versión)	7.252	7.252	8	4	30 min
C (segunda versión)	7.252	7.252	8	4	31 min
Total					**3 h 8 min**

- **Todos sobreajustan rápido.** Después de la mejor época, la pérdida de train sigue bajando y la de validación sube: el modelo empieza a memorizar train. El early stopping corta a tiempo y se queda la mejor época.
- **A y B llegan a su mejor punto con la misma cantidad de muestras vistas** (~30.800): 3 épocas de A o 1 de B.
- **Predicción:** ~12 ms por imagen en lote con la GPU del M4.

7 Cómo evaluamos

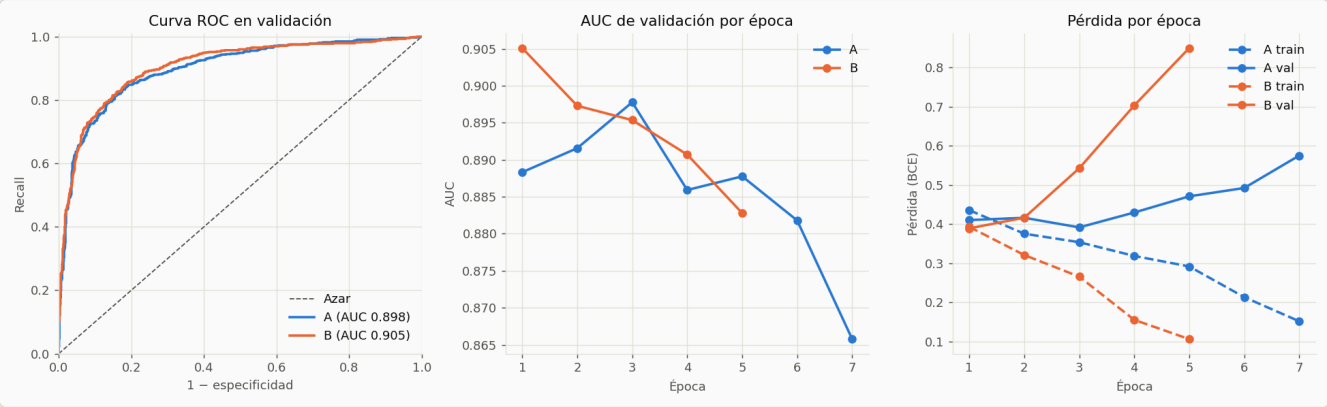
1. **Train** ajusta los pesos. **Validación** elige la época, el umbral y el modelo final.
2. **Test se usa una sola vez**, con el modelo y el umbral ya fijados. El comando de evaluación se niega a evaluar dos veces el mismo conjunto. Las decisiones se escribieron antes de abrir test.
3. **Intervalos de confianza del 95%** por bootstrap: 2.000 remuestreos **por paciente**, porque las imágenes de un mismo paciente no son independientes.

4. **Comparaciones pareadas:** dos modelos se comparan sobre exactamente las mismas imágenes. Una diferencia es significativa si su intervalo no incluye el 0.

8 Modelos A y B en validación

	A	B	B – A (IC 95%)
F1	0,795	0,800	+0,005 (–0,010 a +0,021)
AUC	0,898	0,905	+0,007 (–0,002 a +0,016)
Recall	81,4%	85,5%	**+4,1 pts (+2,2 a +6,2)**
Especificidad	84,5%	81,2%	**–3,3 pts (–5,2 a –1,6)**
Precisión	77,7%	75,2%	–2,6 pts (–4,6 a –0,7)
Umbral elegido	0,379	0,414	

- **Sin diferencia significativa en F1 ni en AUC:** con H0 "la diferencia es 0" y α = 0,05, los intervalos de la diferencia incluyen el 0, así que no se rechaza H0. Eso no prueba que A y B sean iguales.
- **Cambia el punto de operación:** B detecta más derrames y da más falsas alarmas. Eso sí es significativo.
- **Decisión, antes de abrir test:** el modelo final es B, por tener el mayor AUC de validación, el mismo criterio que eligió la época. A no se evalúa en test.



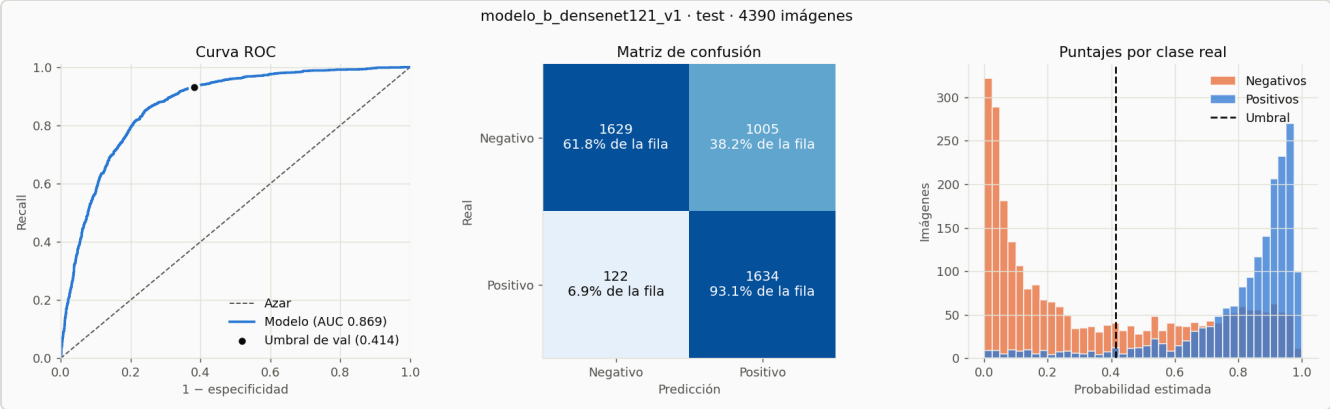
Curvas ROC en validación, AUC de validación por época y pérdida de train y validación por época.

9 Modelo B en el test oficial

4.390 imágenes de 1.686 pacientes, con 1.756 positivas. Umbral 0,414, fijado en validación.

	Test (IC 95%)	Validación	Siempre positivo
F1	**0,744** (0,726 a 0,761)	0,800	0,571
AUC	0,869 (0,858 a 0,880)	0,905	0,5
Recall	93,1% (91,6 a 94,4)	85,5%	100%
Especificidad	61,8% (59,6 a 64,3)	81,2%	0%
Precisión	61,9% (59,7 a 64,2)	75,2%	40,0%

Matriz de confusión: 1.634 derrames detectados, 122 no detectados, 1.005 falsas alarmas y 1.629 negativas bien clasificadas.



Modelo B en el test oficial: curva ROC con el umbral de validación, matriz de confusión y puntajes por clase real.

Por qué test salió peor que validación

El problema son las **falsas alarmas**: la especificidad cae de 81% a 62%. Parte de la causa es que el test oficial tiene otra población: muchos más pacientes con 10 o más estudios previos, probablemente internados. Con la mezcla de validación, la especificidad sería 69% en lugar de 62%. Entre las negativas, el puntaje del modelo sube con los estudios previos (correlación de Spearman 0,49 en test, IC 95% 0,45 a 0,52), y entre las positivas no: el modelo usa en parte la señal "paciente internado".

Estudios previos	Negativas en val	Negativas en test	Especificidad val	Especificidad test	AUC test
0	46,8%	34,3%	88,6%	87,9%	0,957
1 a 9	44,2%	40,9%	77,5%	56,2%	0,845
10 o más	9,0%	24,8%	60,2%	35,0%	0,779

- **Otros hallazgos confunden:** la especificidad es 69,9% contra negativas sin hallazgos y 47,0% contra negativas con otros hallazgos.
- **El umbral no lo arregla.** Aun eligiéndolo mirando test, que no está permitido, el mejor F1 posible era 0,769. No se cambió.
- **Posible atajo:** el número de estudios previos, sin mirar la imagen, ya separa positivas de negativas con AUC 0,73 en test. El modelo podría estar aprendiendo signos de "paciente internado", como dispositivos, además del derrame.
- **Ruido en las etiquetas:** varias falsas alarmas con puntaje 0,98 están etiquetadas *No Finding*, pero muestran opacidades evidentes. Confirmarlo requiere un radiólogo.

10 Modelo C: intento de llegar a 0,80

Hipótesis: si las negativas de train tienen la misma mezcla de estudios previos que el test oficial, el modelo aprende a no confundir "paciente con muchos estudios" con derrame y da menos falsas alarmas.

Por qué hizo falta un test nuevo

El test oficial ya se había usado para evaluar B y para analizar sus errores. Evaluar ahí un modelo diseñado a partir de esos errores daría un resultado optimista. Por eso:

- Las imágenes del test oficial quedaron **afuera** de este experimento.
- Train (60%), validación (15%) y un **test nuevo** (25%) salen de los pacientes de `train_val_list.txt`, divididos por paciente.

- Validación y test nuevo se armaron con **la misma mezcla de estudios previos que el test oficial**: el 53% de las positivas viene de pacientes con 10 o más estudios.
- Se entrenó un **control** con exactamente los mismos pacientes, la misma cantidad de imágenes y los hiperparámetros del modelo A. **La única diferencia** es cómo se eligen las negativas de train: al azar en el control y con la mezcla del test oficial en C.

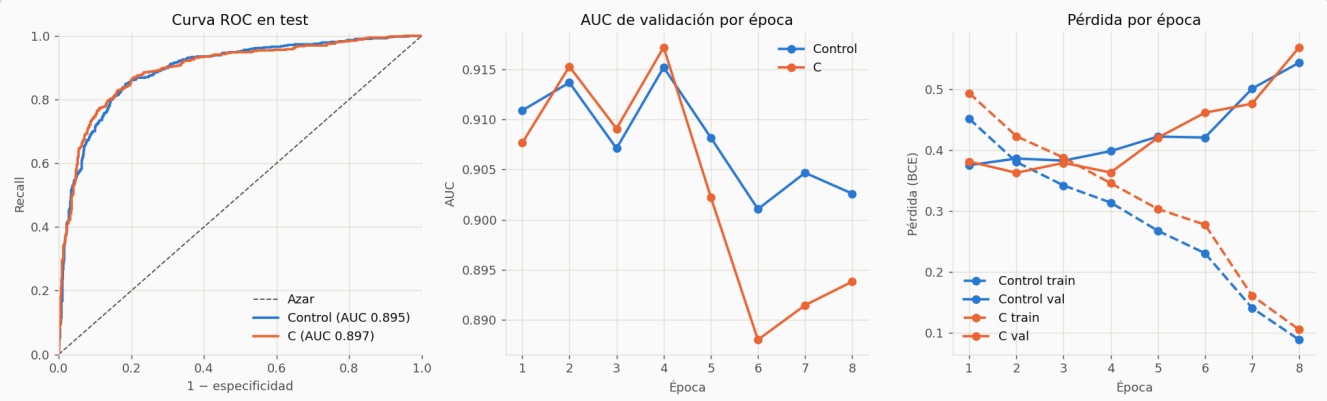
Conjunto	Imágenes	Pacientes	Positivas	Negativas con 10+ estudios
Train del control	7.252	4.749	2.901	361 (8,3%)
Train de C	7.252	4.350	2.901	1.080 (24,8%)
Validación, igual en los dos	732	498	293	109 (24,8%)
Test nuevo, igual en los dos	1.313	865	525	196 (24,9%)

Train es más chico que en A y B (2.901 positivas contra 4.108): las positivas de los pacientes de validación y test que no entraban en la mezcla no podían pasar a train, porque serían los mismos pacientes. Por eso el control es necesario: compara contra la misma cantidad de datos.

Criterio fijado antes de abrir el test nuevo: éxito si C saca F1 ≥ 0,80. C mejora al control si el intervalo de la diferencia de F1 queda entero por encima de 0.

Resultados

Test nuevo	Control	Modelo C	C – control (IC 95%)
F1 (IC 95%)	0,775 (0,729 a 0,814)	**0,784** (0,736 a 0,823)	+0,009 (–0,015 a +0,033)
AUC	0,895	0,897	+0,002 (–0,010 a +0,013)
Recall	74,7%	73,0%	–1,7 pts (–5,3 a +1,6)
Especificidad	87,9%	91,2%	**+3,3 pts (+1,4 a +5,3)**
Precisión	80,5%	84,7%	**+4,2 pts (+1,6 a +7,1)**
Falsas alarmas	95	69	–26
Derrames no detectados	133	142	+9

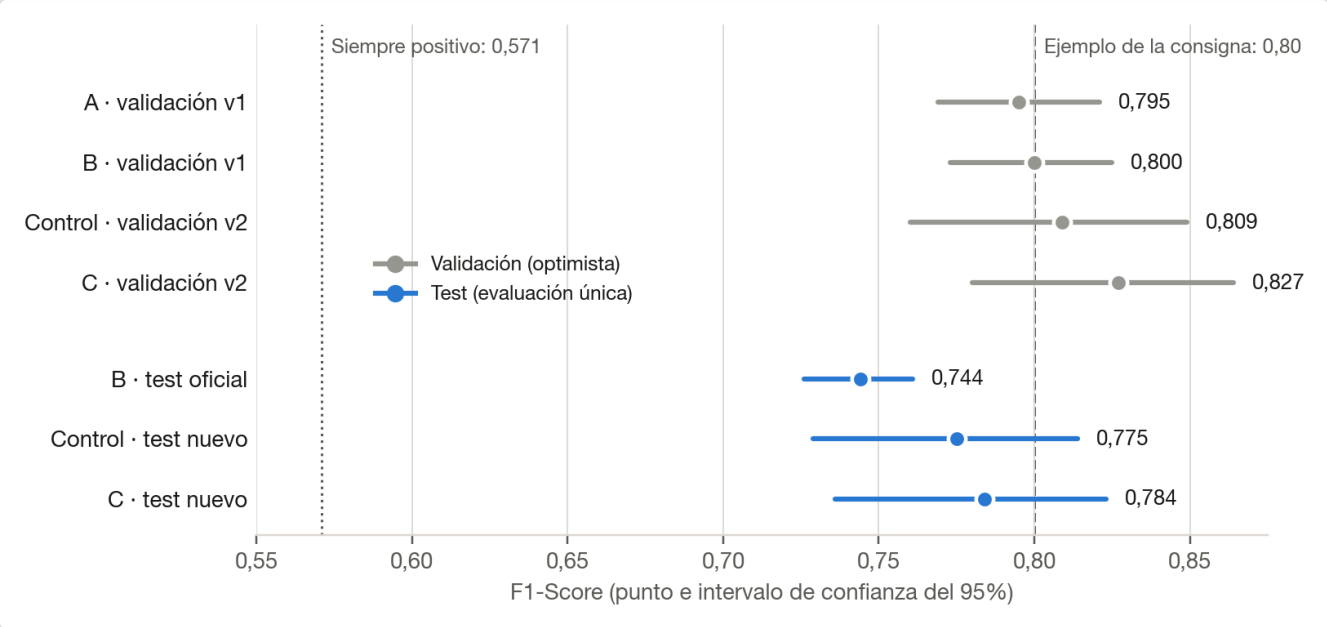


Control y modelo C: curvas ROC en el test nuevo, AUC de validación por época y pérdida por época. Los dos eligieron la época 4.

- **F1 ≥ 0,80: no se cumple.** C saca 0,784. Como el intervalo llega a 0,823, tampoco se puede descartar que el valor real sea 0,80 o más.
- **C mejor que el control en F1: no.** El intervalo de la diferencia incluye el 0.

- **Lo que sí se confirmó:** C da menos falsas alarmas, con especificidad y precisión significativamente mejores. Pero detecta un poco menos, y el F1 casi no se mueve.
- **El test nuevo no reproduce el problema del oficial.** En pacientes con 10 o más estudios previos, hasta el control tiene especificidad 83,7%; B, en el test oficial, tenía 35,0%. La mezcla de estudios previos no alcanza para explicar la caída del test oficial.
- **El límite es la separación entre clases.** Eligiendo el umbral mirando test, el mejor F1 posible sería 0,800 para C. Para pasar 0,80 con margen hace falta un modelo que distinga mejor, no otro umbral.

11 F1 de todos los modelos



F1 de cada modelo con su intervalo de confianza del 95% (bootstrap por paciente). Validación es optimista: ahí se eligieron la época y el umbral.

Modelo	Conjunto	F1 (IC 95%)	AUC	Recall	Especif.	Precisión
A	Validación v1	0,795 (0,769 a 0,821)	0,898	81,4%	84,5%	77,7%
B	Validación v1	0,800 (0,773 a 0,825)	0,905	85,5%	81,2%	75,2%
B	**Test oficial**	**0,744** (0,726 a 0,761)	0,869	93,1%	61,8%	61,9%
Control	Validación v2	0,809 (0,760 a 0,849)	0,915	82,9%	85,2%	78,9%
C	Validación v2	0,827 (0,780 a 0,864)	0,917	81,6%	89,5%	83,9%
Control	Test nuevo	0,775 (0,729 a 0,814)	0,895	74,7%	87,9%	80,5%
C	**Test nuevo**	**0,784** (0,736 a 0,823)	0,897	73,0%	91,2%	84,7%
Siempre positivo	Cualquiera	0,571	0,5	100%	0%	40,0%

El 0,744 y el 0,784 no se comparan directamente: son conjuntos de prueba distintos, con pacientes distintos.

12 Conclusiones

1. **El modelo aprende a detectar derrame:** AUC de 0,87 a 0,90 en pacientes que nunca vio, y F1 muy por encima de la referencia trivial.

2. **No alcanzamos el F1 de 0,80 en test.** El mejor resultado en un test es 0,784, con un intervalo que incluye el 0,80.
3. **Entre sacar negativas y repetir positivas no se detectó una diferencia significativa en F1.** Repetir positivas mueve el modelo hacia más detecciones y más falsas alarmas, y tarda más en entrenar.
4. **Validación sobreestimó el rendimiento**, en parte porque el test oficial tiene otra población de pacientes.
5. **Elegir mejor las negativas (modelo C) baja las falsas alarmas**, pero no alcanza para mejorar el F1 de forma significativa.

Limitaciones

- **Etiquetas con errores**, extraídas automáticamente de los informes.
- **Dispositivos médicos** más frecuentes en las positivas: posible atajo que no medimos.
- **Resolución de 224×224:** los derrames chicos pueden perderse al reducir la imagen.
- **40% de positivas es artificial:** con la proporción real, la precisión y el F1 serían bastante más bajos.
- **Una sola seed por modelo:** no medimos cuánto varía el resultado entre entrenamientos.
- **Hiperparámetros fijos:** learning rate, weight decay y tamaño de lote no se compararon en validación; solo la época y el umbral.
- **Test remezclado:** la submuestra del test oficial es más fácil que el test completo (ver sección 5).
- **Los dos conjuntos de prueba ya se usaron.** Cualquier modelo nuevo necesitaría otro conjunto independiente.

---

13 Cómo reproducirlo

Desde la carpeta `iaproyecto`, con el entorno virtual instalado y las imágenes de NIH en `data/raw/nih`. Los datos no se suben al repositorio; el modelo final (B) sí, en `models/modelo_b_densenet121_v1`, así que `rx-predecir` funciona sin entrenar. Para no pisar el modelo versionado, entrenar con `--salida` hacia otra carpeta.

```
rx-preparar --config configs/nih.json
rx-preparar --config configs/nih_modelo_b.json
rx-entrenar --config configs/modelo_a.json --salida models/modelo_a_nuevo
rx-entrenar --config configs/modelo_b.json --salida models/modelo_b_nuevo
rx-comparar --modelos models/modelo_a_nuevo models/modelo_b_nuevo --nombres A B --salida models/co
mparacion_a_b_nueva
rx-evaluar --modelo models/modelo_b_nuevo --conjunto test
```

El modelo C y su control se reproducen con `configs/nih_v2_control.json`, `configs/nih_v2_c.json`, `configs/modelo_control_v2.json` y `configs/modelo_c_v2.json`; los comandos completos están en `docs/MODELO_C.md`. Para probar el modelo con una radiografía nueva:

```
rx-predecir ruta/a/la/imagen.png
```

El detalle de cada paso está en el repositorio: `docs/SPLITS_NIH_EFFUSION.md` (datos), `docs/RESULTADOS_MODELOS.md` (modelos A y B) y `docs/MODELO_C.md` (modelo C).